Universidad Rafael Landívar
Tradición Jesuita en Guatemala

Marketing Analytics

Actividad – Segmentación de Clientes

Link streamlit: https://marketing-analytics-rafael-alvarez-slzgkks4peysyvm9jttk6z.streamlit.app/

Modalidad – Grupos de trabajo → La entrega de esta actividad es con los grupos de trabajo asignados

Pregunta guía de la sesión: ¿a qué grupos de clientes les hablamos distinto, y cuánto vale cada grupo?

1 · Preguntas previas (5 min)

Respondan entre todos, sin buscar nada:

- ¿Cómo decide hoy una empresa que usted conozca qué ofrecerle a cada cliente? ¿A todos lo mismo, o distinto?
- Si pudiera dividir a sus clientes en solo tres grupos, ¿con qué criterio los dividiría?

Respuesta del grupo:
Nos basaríamos en el historial de la cuenta, en recomendaciones basadas en inteligencia artificial, también basándonos en la región recomendaríamos de acuerdo con la época del año. Dividiríamos en los habituales, los casuales y nuevos.

2 · Segmentar a mano (20 min)

Ejemplo pequeño: tres clientes de una tienda en línea.

Cliente	Ingreso anual (US$)	Visitas a la web por mes
A	30,000	3
B	32,000	15
C	60,000	4

Pregunta 1. Sin calcular nada: ¿cuál de B o C se parece más a A? Anoten por qué.

Respuesta del grupo:
B se parece más a A que C, ya que sus ingresos anuales son muy parecidos, solo con una pequeña diferencia de $2,000, y aunque las visitas de C están más cerca que las de A.

© Todos los derechos reservados Universidad Rafael Landívar URL

Ahora midan la "distancia" entre clientes (qué tan distintos son). La distancia entre dos clientes es la raíz de la suma de las diferencias al cuadrado.

Con los números tal cual (dólares y visitas):

- A–B: diferencia de ingreso 2,000; diferencia de visitas 12. Distancia ≈ 2,000.
- A–C: diferencia de ingreso 30,000; diferencia de visitas 1. Distancia ≈ 30,000.

Pregunta 2. Con ese cálculo, ¿quién está más cerca de A? ¿Les parece razonable, sabiendo que B visita la web 5 veces más que A?

Respuesta del grupo:

B esta más cerca de A con una distancia de 2,000. No nos parece necesariamente razonable por que el ingreso domina por completo el resultado solo por estar medio en miles. Aunque B tiene un ingreso muy similar a A visita la web a 5 veces más, Una diferencia porcentual y de comportamiento muy grande.

Ahora pongan las dos variables en la misma escala (estandarizar): dividan cada diferencia entre la desviación típica de la variable. Supongan que la del ingreso es US$20,000 y la de las visitas es 5.

Pareja	Dif. ingreso ÷ 20,000	Dif. visitas ÷ 5	Distancia
A–B	2,000 ÷ 20,000 = 0.1	12 ÷ 5 = 2.4	≈ 2.40
A–C	30,000 ÷ 20,000 = 1.5	1 ÷ 5 = 0.2	≈ 1.51

Pregunta 3. ¿Quién está más cerca de A ahora? ¿Qué aprendieron sobre estandarizar antes de segmentar?

Respuesta del grupo:

Ahora después de estandarizar la distancia entre A y C es menor que entre A y B, por lo que C esta más cerca de A.

3 · Miren los datos antes de usar Orange (15 min)

Esta es una muestra de la base que usarán en el laboratorio: 2,205 clientes de un retailer de alimentos. Todavía no abran Orange. Con lo que ven aquí, respondan.

Seis clientes al azar (columnas seleccionadas):

id	Ingreso anual (US$)	Edad	Hijos pequeños	Gasto total, 2 años (US$)	Compras web	Compras tienda	Visitas web/mes	Educación
2036	42,554	42	1	41	2	3	4	Licenciatura
749	46,891	55	0	122	2	4	4	Maestría 2.º ciclo

© Todos los derechos reservados Universidad Rafael Landívar URL

2043	54,591	71	0	495	6	8	5	Licenciatura
8	33,454	35	1	146	4	4	8	Doctorado
1562	40,442	68	1	156	3	4	7	Maestría
1404	38,741	62	1	48	2	3	7	Maestría 2.º ciclo

Resumen de algunas variables (los 2,205 clientes):

Variable	Mínimo	Mediana	Promedio	Máximo
Ingreso anual (US$)	1,730	51,287	51,622	113,734
Edad	24	50	51	80
Gasto total, 2 años (US$)	4	343	563	2,491
Días desde la última compra	0	49	49	99

Pregunta 4. ¿Qué creen que son estos datos? ¿Qué tipo de negocio es y quiénes son sus clientes? ¿Qué les llama la atención? (Pista: miren el gasto total, la mediana y el promedio.)

Respuesta del grupo:

Creemos que corresponden a una empresa de ventas de alimentos, de personas que buscan mejorar los hábitos de compra de sus clientes. La información incluye desde edades, ingresos, frecuencia de compras y gastos acumulados en dos años. Lo que nos llama más la atención es la diferencia entre el gasto promedio y la mediana, ya que algunos realizan compras de mayor valor y elevan el promedio general.

Pregunta 5. Hipótesis. Si tuvieran que dividir estos clientes en tres grupos, ¿cuáles serían? Descríbanlos antes de ver ningún resultado:

Grupo (nombre)	Cómo es: ingreso, gasto, compras	% de clientes que esperan	% del gasto que esperan
Consumidores	Ingresos altos y compras frecuentes	30%	60%
Regulares	Ingresos medios y gastos moderados	40%	30%
Bajo consumo	Ingresos bajos y pocas compras	20%	10%

Pregunta 6. ¿Qué dato les haría cambiar de opinión sobre estos grupos? ¿Qué variable creen que separa más a los clientes?

Respuesta del grupo:

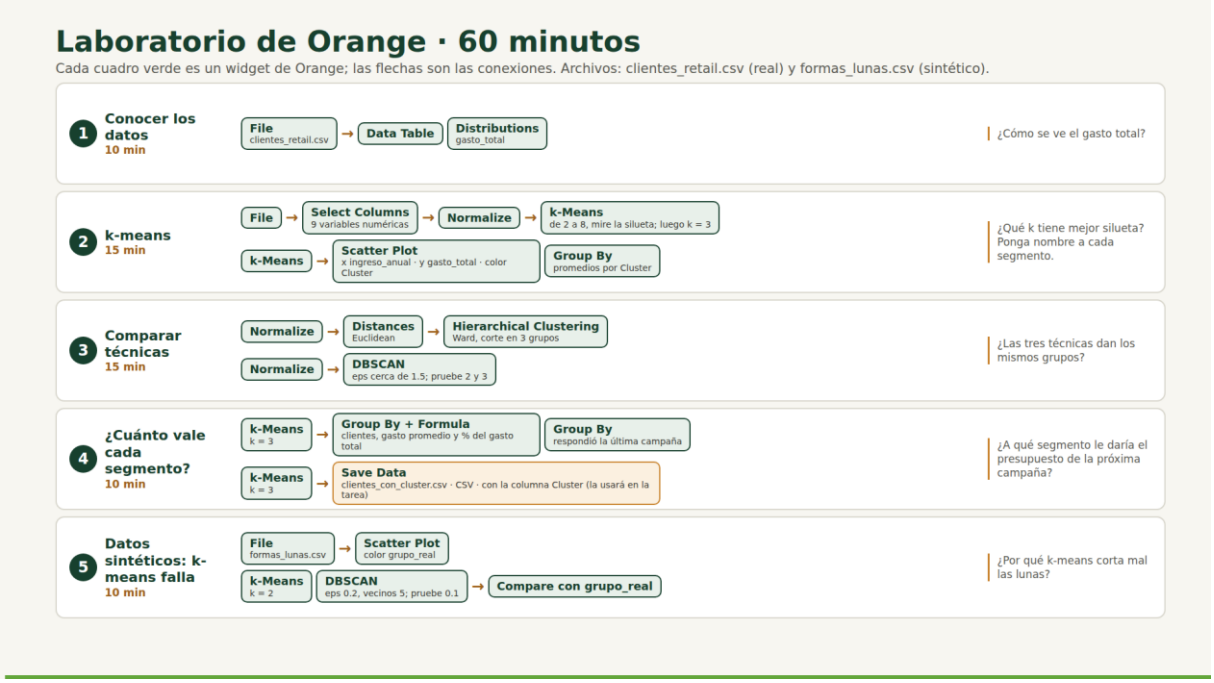
Cambiaríamos de opinión si encontramos que nuestros clientes con ingresos altos no necesariamente son quienes más compran o gastan. También sería importante analizar si existen clientes con ingresos medios que realizan compras frecuentes y generan valor a la empresa.

© Todos los derechos reservados Universidad Rafael Landívar URL

4 · Laboratorio de Orange (≈60 min)

Pregunta de negocio: ¿a qué grupos de clientes les hablamos distinto, y cuánto vale cada grupo?

Se hace después de la presentación. Sigan los pasos tal como están y respondan, en cada parte, las preguntas del laboratorio y las de hallazgos.



Archivos

Archivo	Qué es
clientes_retail.csv	Real. 2,205 clientes de un retailer de alimentos (versión limpia de "Customer Personality Analysis", base abierta). Ingreso, edad, hijos, gasto por categoría, compras por canal, recencia y respuesta a campañas
formas_lunas.csv	Sintético. 400 puntos en forma de dos lunas + 20 de ruido. Sirve para ver dónde falla k-means
formas_alargadas.csv	Sintético. 3 grupos alargados e inclinados. Sirve para el notebook (mezclas gaussianas)

Nota: gasto_total ya es la suma de vinos, frutas, carnes, pescado y dulces. gasto_premium es una parte de ese total, no se suma.

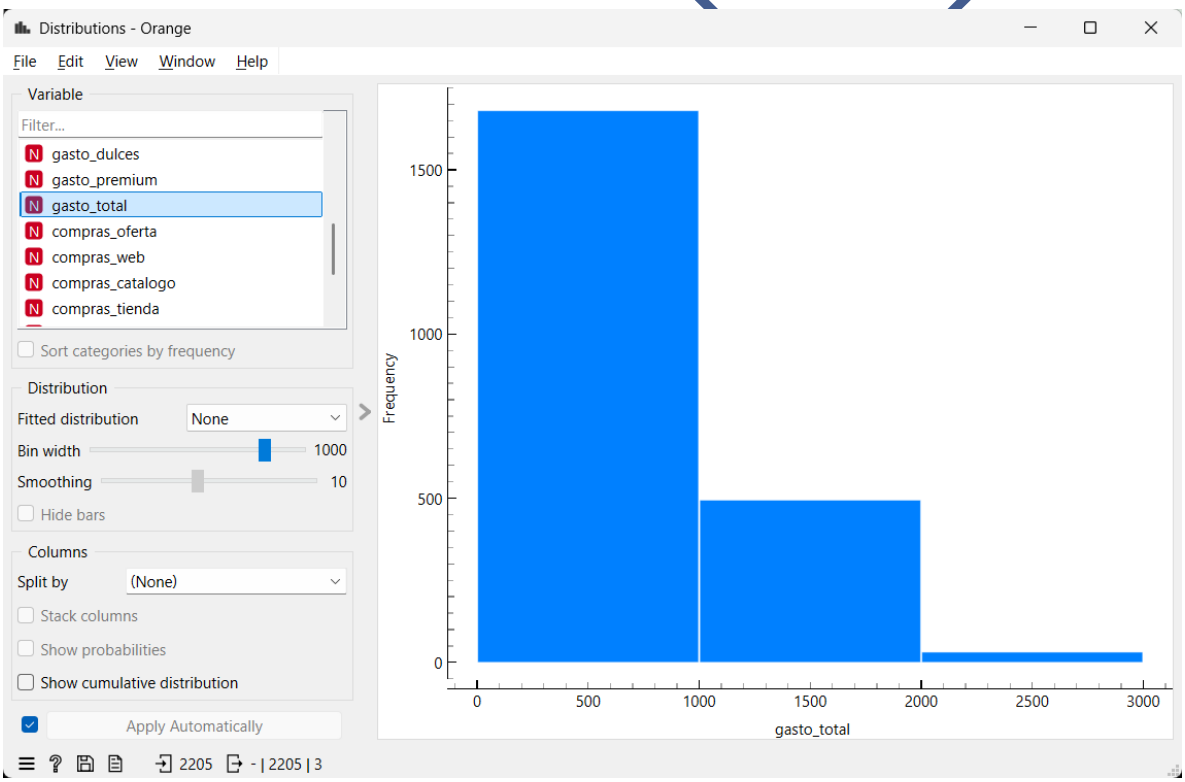
Aviso: los archivos formas_* son datos creados para el ejercicio y no son clientes reales. El archivo clientes_retail.csv es real y proviene de una base abierta.

Parte 1 · Conozca los datos (10 min)

1. File → clientes_retail.csv. Conecte Data Table y Distributions (gasto_total).

© Todos los derechos reservados Universidad Rafael Landívar URL

2. ¿Cómo se ve gasto_total? (Pocos clientes gastan mucho, muchos gastan poco.) **El gasto se concentra en valores bajos y hay un pequeño grupo de clientes que hacen gastos elevados.**



Hallazgo. ¿La forma de gasto_total coincide con lo que vieron en la Pregunta 4 (mediana 343, promedio 563)? ¿Qué significa para un promedio?

Respuesta del grupo:

Si, al analizar la grafica podemos observar que la mayoría de los clientes tienen un gasto bajo, mientras que va aumentando el gasto van disminuyendo los grupos de clientes. El promedio puede verse afectado por los clientes que gastan mucho, por lo que no siempre representa el comportamiento de la mayoría.

Parte 2 · k-means: el punto de partida (15 min)

1. Select Columns: deje como atributos solo ingreso_anual, gasto_total, compras_tienda, compras_web, compras_catalogo, visitas_web_mes, recencia_dias, hijos_pequenos, edad. Todo lo demás a "Ignored" o "Meta".

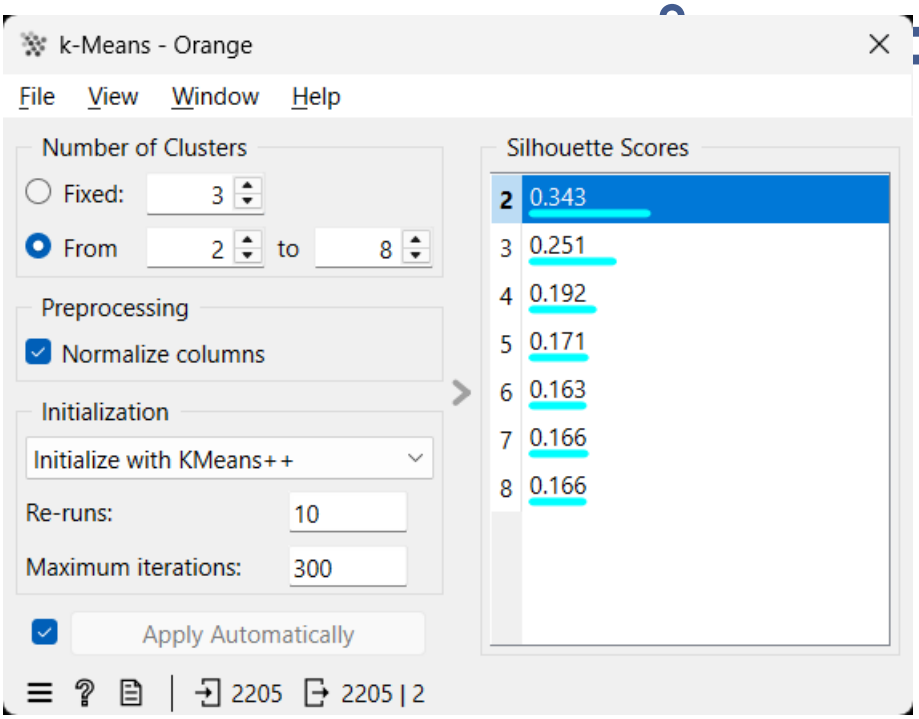
2. Continuize / Normalize (estandarizar por desviación): si no se normaliza, el ingreso (decenas de miles) aplasta a las visitas web (unidades).

3. k-Means con "From 2 to 8" y mire la silueta de cada k.

4. Fije k = 3 y conecte a Scatter Plot (x = ingreso_anual, y = gasto_total, color = Cluster).

© Todos los derechos reservados Universidad Rafael Landívar URL

5. Group By (o Box Plot por Cluster): promedio de cada variable por segmento.



Preguntas del laboratorio: ¿qué k tiene mejor silueta? ¿Es muy alta? ¿Ponga un nombre de negocio a cada segmento?

Respuesta del grupo:

Encontramos que K= 2 tiene la mejor puntuación de silueta con 0.343. La puntuación no es muy alta, pero esto significa que los grupos no están separados y algunos clientes pueden tener características similares. Aunque K2 presenta mejores resultados recomendamos que se utilice K = 3 para analizar con más detalle.

Pregunta 7 (contraste con su hipótesis). Anoten lo que encontraron y compárenlo con la Pregunta 5.

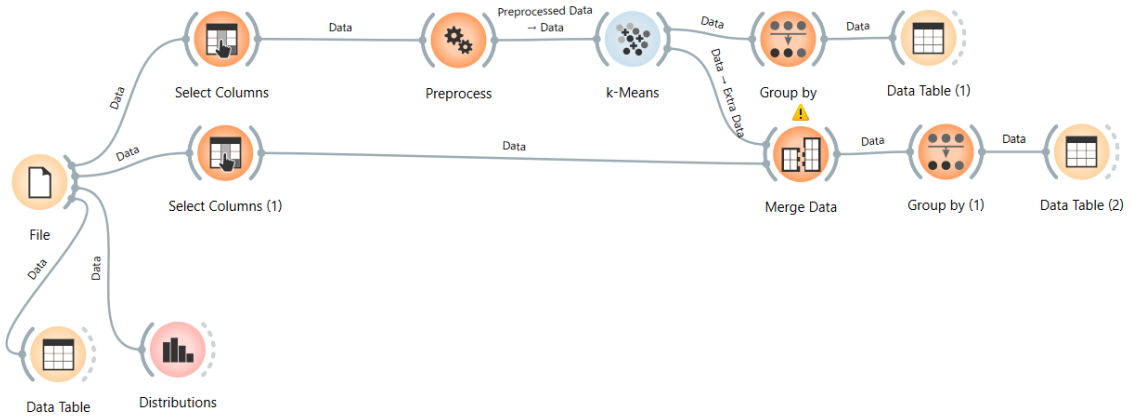
Segmento (nombre de negocio)	Clientes	Ingreso promedio	Gasto promedio	¿Se parece a su hipótesis? ¿Qué los sorprendió?
1 clientes de alto valor	561	$76116.10	$1303.74	Si, ya que hay un grupo de ingresos altos.
2 clientes Regulares	1013	$33985.60	$85.39	Si, porque esperábamos un grupo con poco gasto.
3 clientes de bajo valor	631	$58158.70	$670.37	No, encontramos un grupo de clientes con un consumo intermedio.

© Todos los derechos reservados Universidad Rafael Landívar URL

Capture aquí el Scatter Plot de k-means (k = 3).

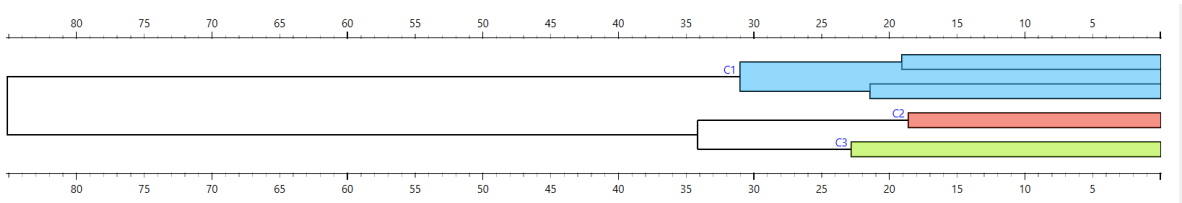
Respuesta del grupo:

Al comparar nuestros resultados, encontramos que los clientes si se pueden dividir en tres grupos según sus ingresos y gastos. El grupo de mayor tamaño no es el que más valor genera, lo que demuestra la importancia de segmentar a los clientes para realizar estrategias diferentes.

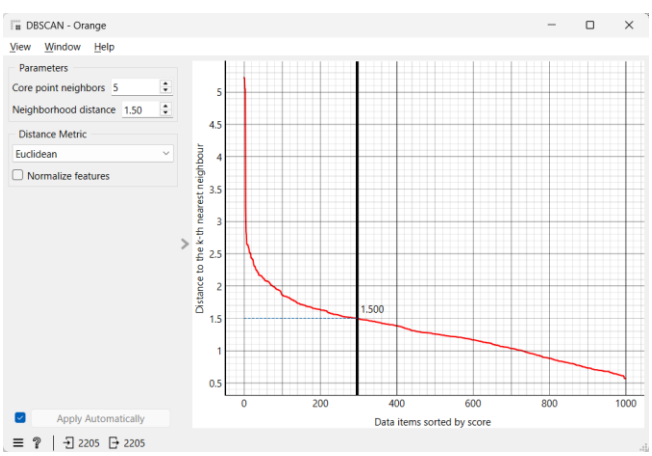


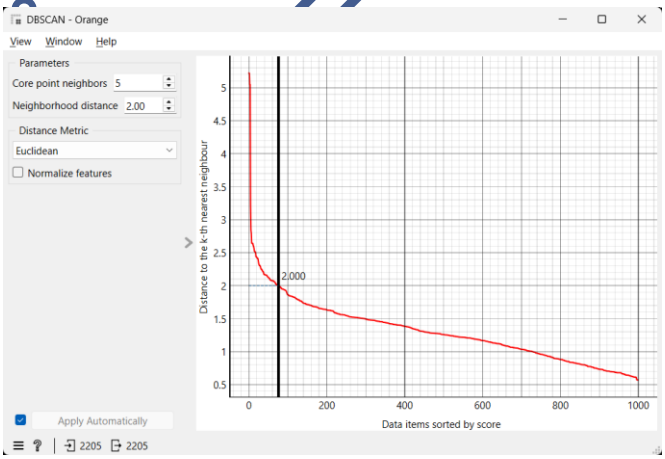
Parte 3 · Compare técnicas (15 min)

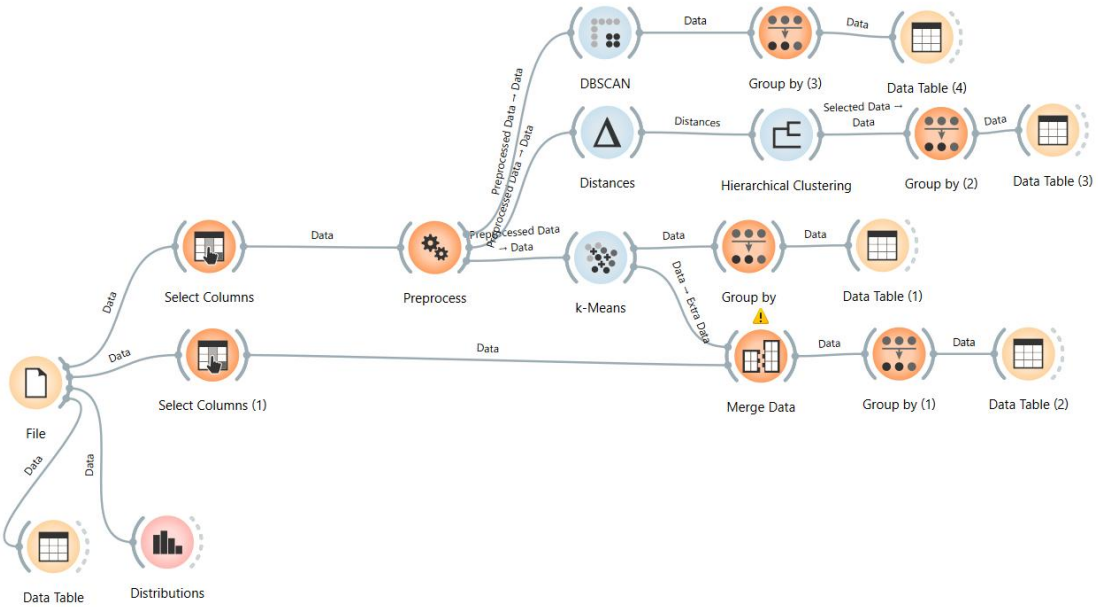
1. Con los datos normalizados, conecte Distances (Euclidean) → Hierarchical Clustering (Ward). Corte en 3 grupos.
2. Conecte los datos normalizados a DBSCAN. Use el gráfico de distancia al k-ésimo vecino para escoger eps; pruebe cerca de 1.5 y compare con 2 o 3.
3. Compare cuántos clientes caen en cada grupo con cada técnica (Merge Data o Scatter Plot coloreado).



© Todos los derechos reservados Universidad Rafael Landívar URL







Preguntas del laboratorio: ¿las tres técnicas dan los mismos grupos? ¿Qué pasa con DBSCAN al subir eps? ¿Cuál le serviría más a marketing para actuar?

Respuesta del grupo:

No generan exactamente la misma distribución de clientes. Con k-means encontramos tres grupos de 561, 1013 y 631 clientes, mientras que con Ward obtuvimos grupos de 980, 372 y 853 clientes. Con DBSCAN al aumentar epsilon de 1.5 a 3 los clientes los clientes se concentran menos, con 1.5 los tres grupos son visibles, mientras que con 2 y 3 todos se agrupan en uno solo.

© Todos los derechos reservados Universidad Rafael Landívar URL

Pregunta 8. Una segmentación puede ser estadísticamente correcta y no servir para nada. Un segmento útil cumple cinco condiciones:

Condición	Significa
Medible	Se puede calcular con datos que tenemos
Diferenciable	Los grupos se comportan distinto entre sí
Accionable	Podemos hacer algo distinto con cada uno
Rentable	El grupo es lo bastante grande o valioso
Estable	No cambia por completo cada mes

Evalúen las tres técnicas de esta parte con sus propios resultados (sí / parcial / no) y recomienden una. ¿Alguna no sirve en absoluto?

Técnica	Medible	Diferenciable	Accionable	Rentable	Estable	Nº de grupos y ruido
k-means (k = 3)	Si	Si	Si	Si	Parcial	3 grupos sin ruido
Jerárquico (Ward, 3 grupos)	Si	Parcial	Parcial	Parcial	Parcial	3 grupos sin ruido
DBSCAN (su eps)	Si	parcial	parcial	parcial	parcial	3 grupos y 143 de ruido

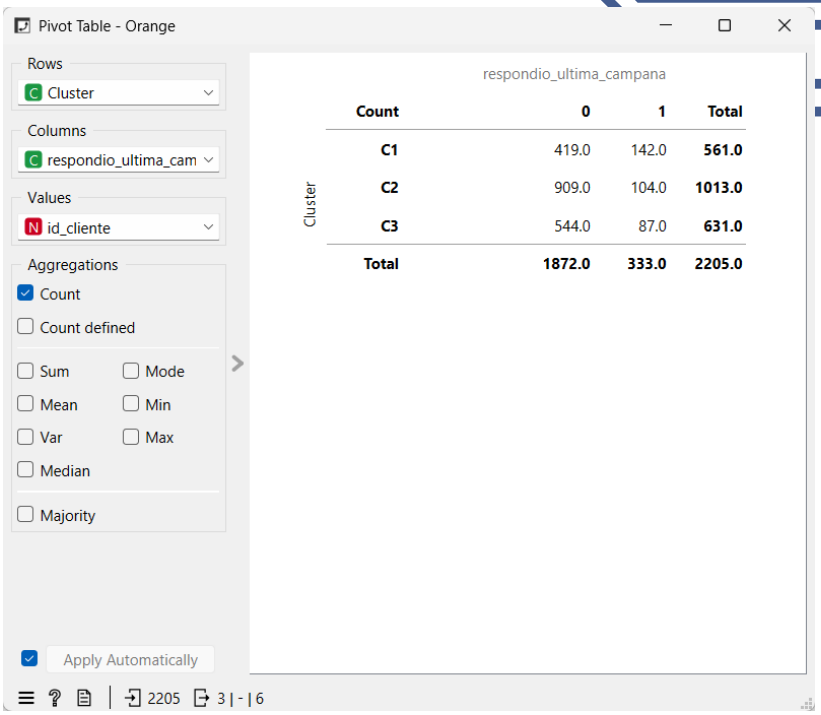
Respuesta del grupo:

Recomendamos utilizar k-means para la segmentación de clientes, porque permite identificar tres grupos medibles y poder diferenciarlos según sus ingresos y gastos. Al final todas las técnicas agregan valor, pero por las necesidades del ejercicio consideramos que k-means nos da resultados más fáciles de interpretar y utilizar.

Parte 4 · ¿Cuánto vale cada segmento? (10 min)

1. Con los grupos de k-means (k = 3), calcule por segmento: número de clientes, gasto promedio y % del gasto total (Group By + Formula).
2. Mire también respondio_ultima_campana por segmento.

© Todos los derechos reservados Universidad Rafael Landívar URL



Preguntas del laboratorio: ¿qué % de clientes genera qué % del gasto? ¿A qué segmento le gastaría el presupuesto de la próxima campaña y por qué? (Recuerde el CLV/CAC de las semanas anteriores.) **El segmento C1 presenta el 25.44% de los clientes, pero genera aproximadamente 58.94%del gasto total, C2 tiene un 45.94% de los clientes y solamente genera el 6.97% de gasto. Consideramos que nos sale mejo invertir en C1 porque tiene mayor gasto promedio y también tiene la mayor tasa de respuesta a la ultima campaña.**

Guarde su segmentación (la usará en la tarea):

1. Conecte la salida Data de k-Means (k = 3) a Save Data.
2. Formato CSV, nombre clientes_con_cluster.csv.
3. Ábralo y compruebe que trae la columna Cluster con los valores C1, C2 y C3.

Nota: lo más simple en Orange es guardar la asignación de cada cliente. Un archivo .joblib no es el formato de Orange; los modelos de Python (notebook) sí se guardan así.

Valor por segmento (con sus resultados):

Segmento	Clientes	% de clientes	Gasto medio (US$)	% del gasto total	% que respondió la última campaña
1 Alto valor	561	25.44%	$1303.74	58.84%	25.31%
2 Bajo consumo	1013	49.94%	$85.39	6.96%	10.27%
3 Regulares	631	28.62%	$670.37	34.04%	13.79%

© Todos los derechos reservados Universidad Rafael Landívar URL

Pregunta 9. Un grupo pequeño de clientes suele generar la mayor parte del gasto. ¿Qué encontraron? ¿Qué haría distinto con cada segmento (retener, crecer, adquirir, no invertir)? Conecten con lo visto antes: CLV, CAC y razón CLV/CAC.

Respuesta del grupo:

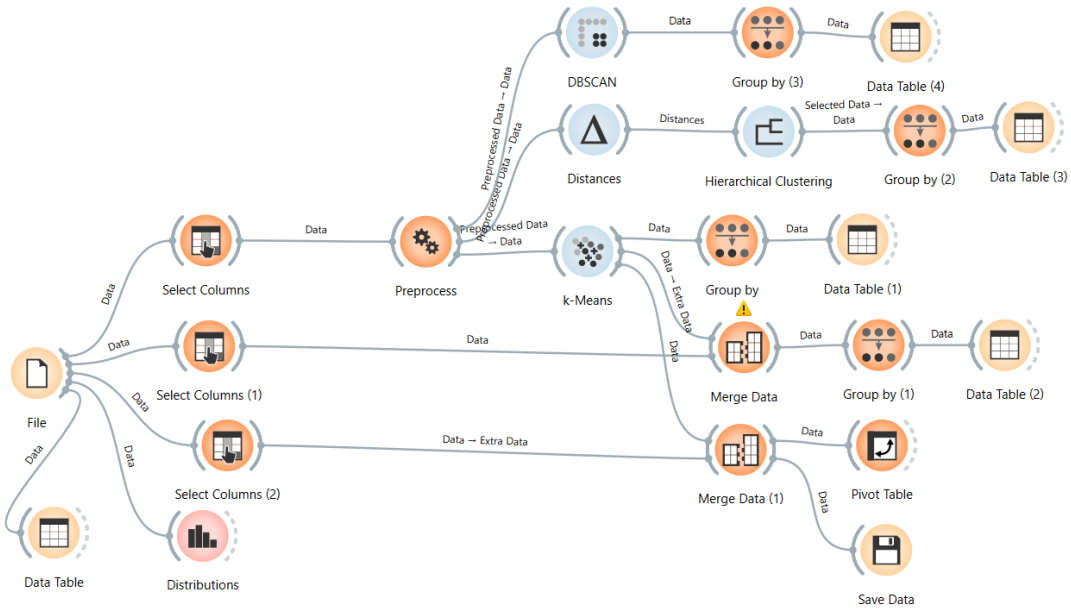
Para el segmento C1 aplicaríamos estrategias de retención, ofreciendo beneficios exclusivos y programas de fidelización, ya que son nuestros clientes mas importantes. Para C3 buscaríamos aumentar su frecuencia de compra mediante promociones personalizada, mientras que para C2 serian con campañas de bajo costo para no realizar inversiones elevadas sin comprobar su potencial de crecimiento.

Pregunta 10 (cálculo). Ejercicio ilustrativo: suponga un margen de 20% sobre el gasto y una campaña que cuesta US$10 por cliente contactado. Con el gasto medio de su tabla, calculen el margen de un cliente de dos años en el segmento de más gasto y en el de menos, y comparen con el costo de la campaña.

Pista: margen = 20% × gasto medio. ¿En qué segmento conviene más gastar los US$10?

Respuesta del grupo:

Al calcular el marge de 20% encontramos que un cliente de C1, con un gasto promedio de $1303.74 durante dos años, generan un margen de $260.75, quitando lo de la campaña nos quedaríamos con $250.75. Consideramos que conviene priorizar la inversión de $10 en el segmento 1, ya que tenemos un margen mucho mayor y también la tasa de respuesta más alta.



© Todos los derechos reservados Universidad Rafael Landívar URL

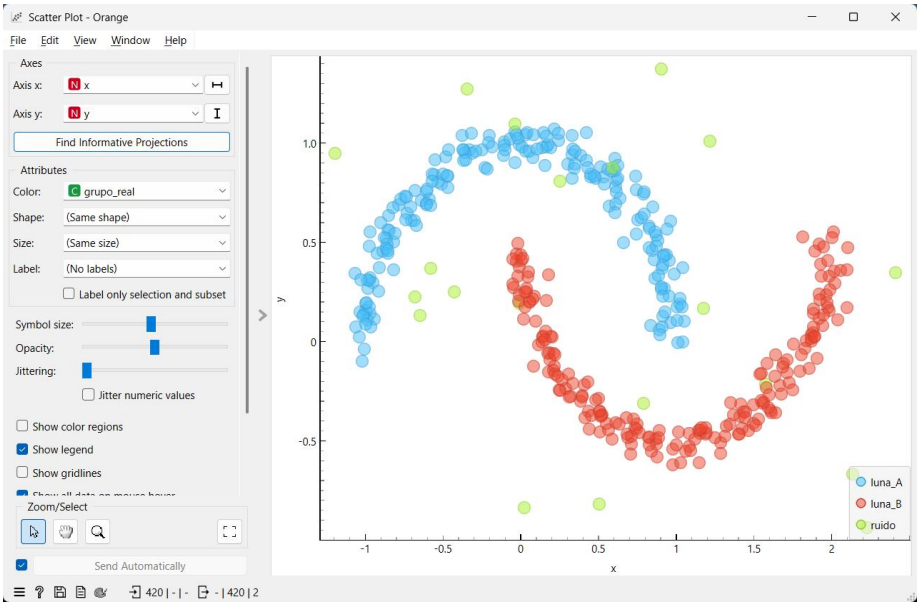
Parte 5 · Datos sintéticos: cuando k-means falla (10 min)

1. File → formas_lunas.csv. Scatter Plot (x, y; color = grupo_real).

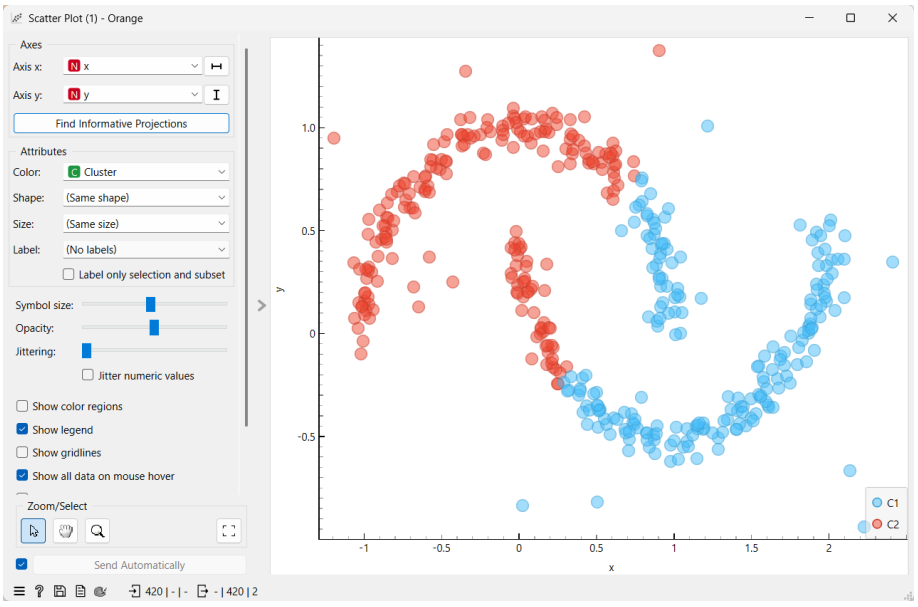
2. k-Means con k = 2 y mire cómo parte las lunas. Luego DBSCAN directo sobre x e y (sin estandarizar): pruebe eps ≈ 0.2 y min vecinos = 5. Pruebe también eps = 0.1.

3. Compare con grupo_real.

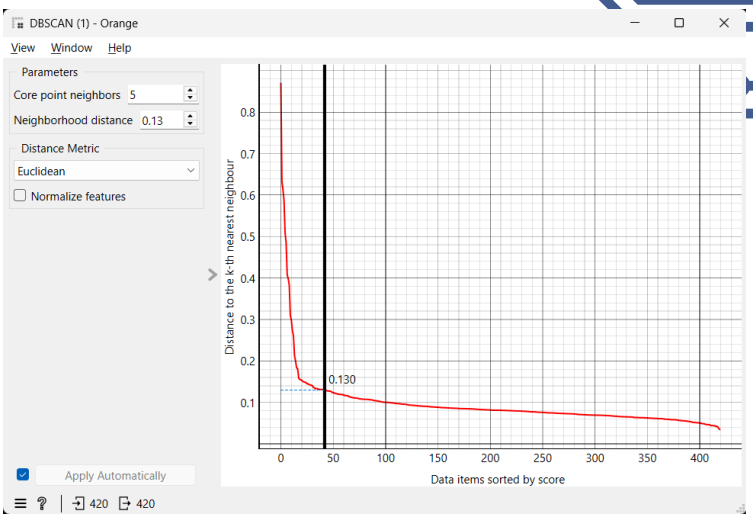
Grupo deal



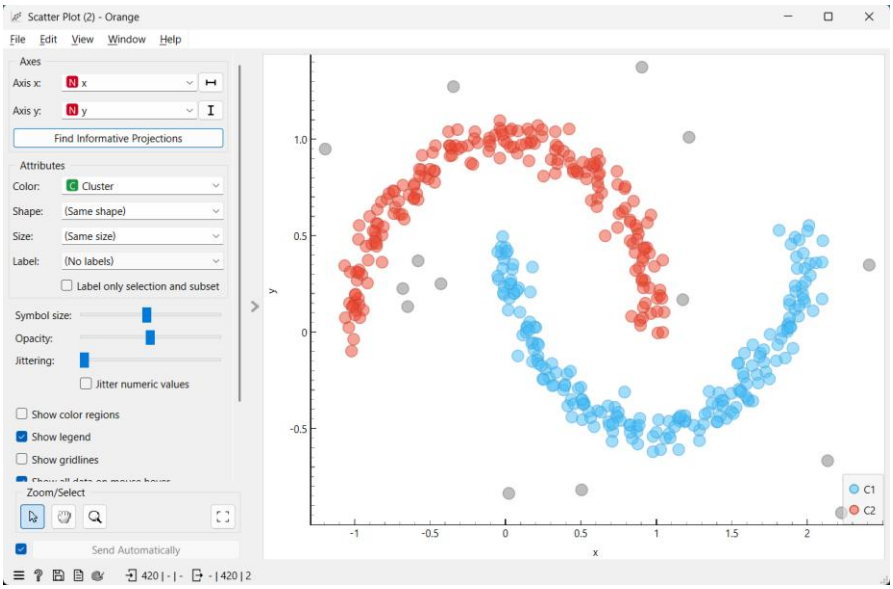
Cluster



© Todos los derechos reservados Universidad Rafael Landívar URL



DBSCAN



Preguntas del laboratorio: ¿por qué k-means corta mal? ¿Qué hizo DBSCAN con el ruido? ¿Cuándo sospecharía que sus clientes no tienen forma de "bolas"?

Respuesta del grupo:

Al comparar los gráficos se observa que K-means no separo correctamente las dos lunas, porque agrupa según la distancia de los centroides y no se adapta bien. BDSCAN identifica mejor las dos lunas y dejo los puntos aislados como ruido. Si sospechamos que los clientes no forman grupos compactos cuando presenta comportamientos de compra diferentes.

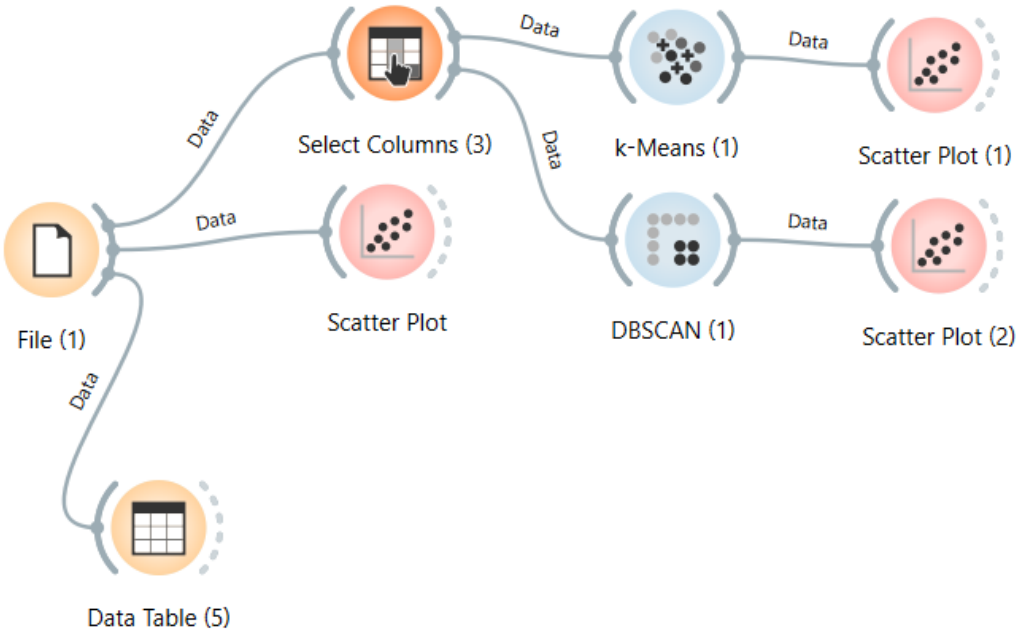
Pregunta 11. En los clientes reales, DBSCAN dio un resultado distinto al de las lunas. ¿Por qué funcionó en un caso y no en el otro? ¿Qué le diría a un gerente que quiere "la técnica más moderna"?

© Todos los derechos reservados Universidad Rafael Landívar URL

Respuesta del grupo:

BDSCAN funciono mejor con las lunas porque los datos tenían dos formas curvas claramente definidas, lo que permitió identificar grupos según su densidad y separar los puntos de ruido. Le diríamos al gerente que no siempre la técnica mas moderna es la mejor, es saber elegir los segmentos útiles para el negocio. En nuestro caso k-means fue el mas practico para segmentar clientes.

Lo que Orange no trae (mezclas gaussianas y k-prototypes) está en el notebook, que es parte de la tarea.



5 · Riesgos de segmentar (10 min)

Pregunta 12. Las variables de la base incluyen edad, hijos y estado civil. ¿Es correcto segmentar con ellas? ¿Dónde está el límite entre personalizar y discriminar o invadir la privacidad?

Respuesta del grupo:

Consideramos que, si es posible utilizar variables como edad, hijos, estado civil para segmentar clientes, siempre que tenga una finalidad clara y se utilicen de manera responsable, el limite esta cuando se utilizan para excluir, discriminar o dar un trato injusto a determinados grupos. Creemos que la segmentación debe servir para mejor la experiencia del cliente y no para aprovecharse de sus características.

© Todos los derechos reservados Universidad Rafael Landívar URL

Pregunta 13. Los segmentos cambian: un cliente de bajo gasto puede crecer, y uno de alto valor puede irse. ¿Cada cuánto recalcularían la segmentación y qué señales vigilarían?

Respuesta del grupo:

Recalcularíamos la segmentación cada tres mese para identificar cambios importantes en el comportamiento de los clientes, sin embargo, revisaríamos mensualmente algunos indicadores para detectar posibles cambios. Antes de que afecten el negocio. Las principales señales que vigilaríamos serian la frecuencia de compra, el gasto y los días desde la ultima compra. Con esto nos aseguramos que la empresa podría mantener la segmentación actualizada.

6 · Conclusiones (10 min)

Escriban en tres líneas qué segmentación recomendarían a marketing, con qué técnica y qué acción tomarían con el segmento más valioso.

Respuesta del grupo:

Recomendaríamos utilizar k-means con tres segmentos, ya que nos permitió identificar que clientes de alto valor, regulares y de bajo valor, facilitando la creación de estrategias.

Anexo · Notebook de la tarea: mezclas gaussianas y k-prototypes

Lo que Orange no trae. Se hace después de la sesión, en casa, como parte de la tarea. Son seis pasos, de arriba hacia abajo.

Pasos

1. Abra el notebook en Google Colab (colab.research.google.com → Archivo → Subir cuaderno) o en Jupyter. El archivo es notebook_segmentacion.ipynb.
2. Suba los dos CSV junto al notebook: clientes_retail.csv y formas_alargadas.csv. En Colab: ícono de carpeta a la izquierda → Subir. El notebook no usa formas_lunas.
3. Ejecute las celdas en orden, de arriba hacia abajo (Mayús + Enter en cada una). La primera instala kmodes y tarda unos segundos.
4. Sección 1 · Mezclas gaussianas. Con formas_alargadas.csv, compare k-means y GMM contra la respuesta real (grupo_real). La segunda celda cuenta los puntos "con duda" (son datos sintéticos, no clientes): los que no tienen ninguna probabilidad mayor a 0.9.
5. Sección 2 · K-prototypes. Con clientes_retail.csv, segmente con números y categorías (educación y estado civil) en un solo modelo.
6. Sección 3 · ¿Coinciden con k-means? Compare k-prototypes contra k-means: el acuerdo (1 = idénticos) y la tabla cruzada.

© Todos los derechos reservados Universidad Rafael Landívar URL

Preguntas

Pregunta N1. ¿Por qué GMM acierta más que k-means con los grupos alargados? ¿Qué ventaja extra tiene (pista: da una probabilidad de pertenecer a cada grupo)?

Respuesta del grupo:

GMM puede identificar mejor los grupos alargados porque permite representar distribuciones de diferentes formas y orientaciones, por otro lado, k-means agrupa según la distancia a los centroides. GMM proporciona probabilidad de pertenencia a cada grupo. GMM alcanzo un 0.97 con los grupos reales, mientras que k-means 0.82.

Pregunta N2. ¿Cuántos puntos quedaron "con duda"? Si fueran clientes reales, ¿qué haría marketing con ellos en vez de forzarlos a un solo grupo?

Respuesta del grupo:

Representan observaciones que no tienen una probabilidad superior al 90% de pertenecer a un grupo especifico. Si fueran clientes reales, consideramos que marketing debería analizar su comportamiento antes de asignarlo a un segmento. Se puede minimizar con campañas de prueba y recopilando información adiciona para dar una mejor respuesta.

```
Acuerdo k-means vs k-prototypes: 0.99
k-prototypes    0    1     2
k-means
0               1  560     0
1               1    0  1012
2             625    6     0
```

Pregunta N3. ¿Agregar educación y estado civil (k-prototypes) cambió los grupos respecto a k-means? ¿Cambia el gasto medio por segmento según la técnica?

Respuesta del grupo:

Se encontró que los grupos no cambiaron respecto a k-means, el tabal cruzado nos mostró que 8 de 2205 clientes quedaron en grupos diferentes, el gasto promedio se mantuvo muy similar en ambas técnicas. Para estos datos agregar variables categóricas no produjo cambios importantes en la segmentación.

Pregunta N4. ¿Qué segmentación le daría a marketing y por qué? Contesten en 3 líneas, con la técnica y la acción que tomarían.

Respuesta del grupo:

Recomendaríamos utilizar k-means con tres segmentos para que los clientes de alto valor sean identificables. Se buscaría aumentar sus compras, mientras que los de bajo consumo utilizaríamos campañas de menor costo.

© Todos los derechos reservados Universidad Rafael Landívar URL

Guarde sus resultados

La última sección (4) guarda lo que usará en la app de Streamlit. Ejecute esa celda al final y compruebe que se crearon los tres archivos:

Archivo	Qué contiene
segmentos_notebook.csv	La asignación de cada cliente (columnas seg_kmeans, seg_gmm, seg_kproto y Cluster). Es lo que sube al visor de la app
modelo_gmm.joblib	El modelo de mezclas gaussianas ajustado, con su estandarizador y la lista de variables
modelo_kproto.joblib	El modelo de k-prototypes ajustado, con las variables numéricas y categóricas

Nota: la columna Cluster toma la técnica que usted recomienda (por defecto k-prototypes). Cámbiela en la celda si prefiere otra.

Entregable

- Este documento con las respuestas del grupo.
- Capturas del laboratorio de Orange: Scatter Plot de k-means (k = 3), árbol jerárquico cortado en 3 grupos, gráfico de distancia de DBSCAN con su eps, y la tabla de valor por segmento.
- Formato: PDF, entregado por Teams.
- Tarea, después de la sesión: el notebook ejecutado (con sus archivos segmentos_notebook.csv y los dos .joblib) y la app en Streamlit (app.py y requirements.txt), según TAREA_Segmentacion.

© Todos los derechos reservados Universidad Rafael Landívar URL